
Estimación Puntual

Cristopher Morales Ubal
e-mail: c.m.ubal@gmail.com

Supongamos que deseamos estudiar la familia de probabilidades $P = \{\mathbb{P}_{\underline{\theta}} : \underline{\theta} \in \Theta\}$ donde \mathbb{P}_{Θ} es de forma conocida solo que se desconoce el valor paramétrico $\underline{\theta} \in \Theta$. Un procedimiento para resolver este problema es elegir un vector $\underline{\theta} \in \Theta$ utilizando algún criterio conveniente basado en una muestra de tamaño n seleccionada.

Nota: Estos apuntes están basados en el libro [1] con el cual aprendí estadística durante mi época de estudiante en la Universidad Técnica Federico Santa María (UTFSM). Han sido escritos en L^AT_EX 2_ε de manera de tener un apunte personal para recordar conceptos importantes de estadística.

Definición: Sea $P = \{\mathbb{P}_{\underline{\theta}}^X : \underline{\theta} \in \Theta\}$ donde \mathbb{P}_{Θ} una familia de probabilidades. Se dice que x_1, x_2, \dots, x_n es una muestra aleatoria (m.a.) proveniente de la familia P ssi X_1, X_2, \dots, X_n son variables aleatorias independientes e idénticamente distribuidas.

Definición: Sea $\chi = \{(x_1, x_2, \dots, x_n) \in \mathbb{R}^n : x_1, x_2, \dots, x_n \text{ es m.a. proveniente de } P\}$ entonces χ se llama espacio de información.

Definición: Sea $\underline{T} : \chi \rightarrow \tau$ una función medible que no depende del parámetro $\underline{\theta} \in \Theta$. Entonces se dice que $\underline{T} = t(\underline{x})$ es una estadística basada en la información χ .

Observación: se denota $\underline{x} = (x_1, x_2, \dots, x_n)$ m.a. de la población.

Definición: Dada una información en un espacio χ se define como estimador de $\underline{\theta} \in \Theta$ a toda estadística $\underline{T} = t(\underline{x})$, tal que

$$\mathbb{P}(t(\underline{x}) - \underline{\theta}) = 0, \forall \underline{\theta} \in \Theta$$

Observaciones:

1. Si $R(\underline{T}) \subset \Theta \implies \underline{T} = t(\underline{x})$ es un estimador de $\underline{\theta}$.
2. Si x_1, x_2, \dots, x_n es una m.a. se tiene que la función de densidad conjunta de \underline{x} es $f_{\underline{\theta}}(\underline{x}) = \prod_{i=1}^n f_{\underline{\theta}}(x_i)$
3. m.a. \Leftrightarrow m.a.s.

Definición: Sea x_1, x_2, \dots, x_n m.a. proveniente de una familia de densidad $f(\bullet, \underline{\theta})$. Se llama *momento muestral de orden r -ésimo* con respecto al origen a la expresión

$$m_r = \frac{1}{n} \sum_{i=1}^n x_i^r$$

Teorema: Sea x_1, x_2, \dots, x_n m.a. proveniente de una familia de densidad $f(\bullet, \underline{\theta})$ y sea $\bar{x}_n = m_1$ (media muestral). Supongamos además que la población tiene varianza finita σ^2 . Entonces

$$\sigma_{\bar{x}_n}^2 = \mathbb{E}[(\bar{x}_n - \mathbb{E}(\bar{x}_n))^2] = \frac{\sigma^2}{n}$$

Definición: Sea $\hat{\underline{\theta}} = \underline{T}(\underline{x})$ estadística basada en χ . Se dice que $\hat{\underline{\theta}}$ es una estadística suficiente de $\underline{\theta} \in \Theta$ si $\forall \underline{\theta}^* = \underline{T}^*(\underline{x})$ estadística de $\underline{\theta}$ se tiene que $f(\hat{\underline{\theta}} | \underline{\theta}^*)$ es independiente de $\underline{\theta}$.

Obs: una estadística es suficiente cuando tenemos la misma capacidad informativa en χ que en $\hat{\underline{\theta}} = t(\underline{x})$.

Teorema (criterio de factorización de Neyman-Fisher)

Sea $\left\{(\chi, \mathcal{B}_{\chi}, \mathbb{P}_{\underline{\theta}}^X) : \underline{\theta} \in \Theta\right\}$ una familia de espacios de probabilidad y sea $f_{\underline{\theta}}$ función de densidad (cuantía) correspondiente a $\mathbb{P}_{\underline{\theta}}^X$. Sea $\underline{T} = t(\underline{x})$ una estadística. Si existe una factorización del tipo:

$$f_{\underline{\theta}}(\underline{x}) = g(\underline{\theta}, t(\underline{x})) \cdot h(\underline{x}) \quad \forall (\underline{\theta}, \underline{x}) \in \Theta \times \chi$$

entonces T es una estadística suficiente para $\underline{\theta} \in \Theta$ (suficiente para la familia).

Ejemplo: Sea x_1, x_2, \dots, x_n m.a. de tamaño n proveniente de una familia $N(\mu, 1)$.
luego

$$\begin{aligned} f(x_1, x_2, \dots, x_n, \mu) &= \prod_{i=1}^n f(x_i, \mu) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2} \left(\frac{x_i - \mu}{1}\right)^2\right) \\ &= \frac{1}{(2\pi)^{n/2}} \exp\left(-\frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2\right) \\ &= \frac{1}{(2\pi)^{n/2}} \exp\left(-\frac{1}{2} \left(\sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i + n\mu^2\right)\right) \\ &= \frac{1}{(2\pi)^{n/2}} \exp\left(-\frac{1}{2} \left(n\mu^2 - 2\mu \sum_{i=1}^n x_i\right)\right) \exp\left(-\frac{1}{2} \sum_{i=1}^n x_i^2\right) \\ &= \frac{1}{(2\pi)^{n/2}} \exp\left(-\frac{n\mu}{2} \left(\mu - 2 \cdot \frac{\sum_{i=1}^n x_i}{n}\right)\right) \exp\left(-\frac{1}{2} \sum_{i=1}^n x_i^2\right) \end{aligned}$$

definiendo

$$\hat{\mu} = \frac{\sum_{i=1}^n x_i}{n}$$

podemos escribir

$$f(x_1, x_2, \dots, x_n, \mu) = g(\mu, \hat{\mu}) \cdot h(x_1, x_2, \dots, x_n)$$

donde

$$g(\mu, \hat{\mu}) = \frac{1}{(2\pi)^{n/2}} \exp\left(-\frac{n\mu}{2} (\mu - 2\hat{\mu})\right) \wedge h(x_1, x_2, \dots, x_n) = \exp\left(-\frac{1}{2} \sum_{i=1}^n x_i^2\right)$$

por lo tanto

$$\hat{\mu} = \frac{\sum_{i=1}^n x_i}{n}$$

es una estadística suficiente para μ .

■

Método de los Momentos

Sea $\left\{(\chi, \mathcal{B}_\chi, \mathbb{P}_{\underline{\theta}}^X) : \underline{\theta} \in \Theta\right\}$ espacio de probabilidad y sea $f_{\underline{\theta}}(x)$ una función de densidad asociada a $\mathbb{P}_{\underline{\theta}}^X$. El método de estimación de los momentos consite en igualar los momentos muestrales con los poblacionales:

$$\mu_r = m_r \iff \mathbb{E}(X^r) = \frac{\sum_{i=1}^n x_i^r}{n}, \quad r = 1, 2, \dots, k$$

donde $\underline{\theta} = (\theta_1, \theta_2, \dots, \theta_k)$ es el vector paramétrico a determinar, resultando de esta forma un sistema de k ecuaciones y k incógnitas $(\theta_1, \theta_2, \dots, \theta_k)$

Ejemplo: Sea x_1, x_2, \dots, x_n una m.a. de tamaño n proveniente de una familia $N(\mu, \sigma^2)$.
en este caso

$$\underline{\theta} = (\mu, \sigma^2)$$

luego aplicando el métodos de los momentos se tiene que:

$$\mu_1 = m_1 \implies \mathbb{E}(X) = \frac{\sum_{i=1}^n x_i}{n} \iff \mu = \frac{\sum_{i=1}^n x_i}{n} \quad (1)$$

$$\mu_2 = m_2 \implies \mathbb{E}(X^2) = \frac{\sum_{i=1}^n x_i^2}{n} \iff \sigma^2 + \mu^2 = \frac{\sum_{i=1}^n x_i^2}{n} \quad (2)$$

asi resolviendo las ecuaciones (1) y (2) para μ y σ^2 se obtiene

$$\hat{\mu} = \frac{\sum_{i=1}^n x_i}{n} = \bar{X}_n$$

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n x_i^2}{n} - \left(\frac{\sum_{i=1}^n x_i}{n} \right)^2 = \bar{X}_n^2 - (\bar{X}_n)^2$$

los cuales son los estimadores obtenidos por el método de los momentos para μ y σ^2 .

■

Método de Máxima Verosimilitud

Definición: sea x_1, x_2, \dots, x_n m.a.de tamaño n , proveniente de la familia de espacios de probabilidades $(\chi, \mathcal{B}_\chi, \mathbb{P}_{\underline{\theta}}^X)$, $\underline{\theta} \in \Theta$ se llama *Función de Verosimilitud* a $L_{\underline{x}} : \Theta \longrightarrow \mathbb{R}$ definida por:

$$L_{\underline{x}}(\underline{\theta}) = f_{\underline{\theta}}(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i, \theta), \quad \underline{\theta} \in \Theta$$

Definición: Sea x_1, x_2, \dots, x_n una m.a. de tamaño n , proveniente de una familia $f(\underline{x}, \underline{\theta})$ y $L_{\underline{x}}(\underline{\theta})$ su función de verosimilitud.

Se llama *Estimador de Maxima Verosimilitud* de $\underline{\theta}$ y se denota por $\hat{\underline{\theta}}$ al $\hat{\underline{\theta}} = t(x_1, x_2, \dots, x_n)$ que maximiza a $L_{\underline{x}}(\underline{\theta})$. Es decir $\hat{\underline{\theta}}$ es el estimador de máxima verosimilitud de $\underline{\theta}$ ssi

- i) $\hat{\underline{\theta}}$ es un estimador de $\underline{\theta}$.
- ii) $L_{\underline{x}}(\hat{\underline{\theta}}) = \sup_{\underline{\theta} \in \Theta} L_{\underline{x}}(\underline{\theta}), \quad \forall \underline{x} \in \chi$

Obs:

1. En general si se satisfacen cierta condiciones de regularidad $L_{\underline{x}}(\underline{\theta})$ es maximo ssi $\nabla L_{\underline{x}}(\underline{\theta}) = \vec{0}$. es decir

$$\frac{\partial L_{\underline{x}}(\underline{\theta})}{\partial \theta_1} = 0, \quad \forall i = 1, 2, \dots, k$$

2. El problema de maximización

$$\max_{\underline{\theta} \in \Theta} L_{\underline{x}}(\underline{\theta}), \quad (*)$$

es equivalente al problema de maximización

$$\max_{\underline{\theta} \in \Theta} \ln(L_{\underline{x}}(\underline{\theta})), \quad (**)$$

asi en general, se resuelve el problema (**) pues es más facil de manejar algebraicamente.

Propiedades de los Estimadores

1. Sea $\hat{\underline{\theta}} = t(\underline{x})$ un estimador de $\underline{\theta}$. Se dice que $\underline{\theta}$ es un *Estimador Insesgado* de $\hat{\underline{\theta}}$ ssi $\mathbb{E}(\hat{\underline{\theta}}) = \underline{\theta}$.
2. Sea $\hat{\underline{\theta}} = t(\underline{x})$ un estimador de $\underline{\theta}$. Se dice que $\underline{\theta}$ es un *Estimador Asintoticamente Insesgado* de $\hat{\underline{\theta}}$ ssi $\lim_{n \rightarrow \infty} \mathbb{E}(\hat{\underline{\theta}}) = \underline{\theta}$.
3. Sea $\{\hat{\underline{\theta}}_n\}_{n \in \mathbb{N}}$ una sucesión de estimadores de $\underline{\theta}$. Esta sucesión se dice *Consistente en Error Cuadrático Medio* ssi

$$\lim_{n \rightarrow \infty} \mathbb{E} \left[\left(\hat{\underline{\theta}}_n - \underline{\theta} \right)^2 \right] = 0$$

Proposición:

$$\lim_{n \rightarrow \infty} \mathbb{E} \left[\left(\hat{\underline{\theta}}_n - \underline{\theta} \right)^2 \right] = 0 \iff \lim_{n \rightarrow \infty} \mathbb{V}(\hat{\underline{\theta}}_n) = 0 \wedge \lim_{n \rightarrow \infty} \mathbb{E}(\hat{\underline{\theta}}_n) = \underline{\theta}$$

4. Sea $\{\hat{\underline{\theta}}_n\}_{n \in \mathbb{N}}$ una sucesión de estimadores de $\underline{\theta}$. Esta sucesión se dice *Consistente Simple* ssi

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(\left| \hat{\underline{\theta}}_n - \underline{\theta} \right| > \epsilon \right) = 0$$

5. Sea $\hat{\underline{\theta}} = t(\underline{x})$ un estimador de $\underline{\theta}$. Se dice que $\hat{\underline{\theta}}$ es un *Estimador Insesgado de Varianza Mínima* ssi

$$\text{i) } \mathbb{E}(\hat{\underline{\theta}}) = \underline{\theta}$$

$$\text{ii) } \mathbb{V}(\hat{\underline{\theta}}) \leq \mathbb{V}(\hat{\underline{\theta}}^*) , \forall \hat{\underline{\theta}}^* \text{ estimador de } \underline{\theta}.$$

Definición: Sean $\hat{\underline{\theta}}$ y $\tilde{\underline{\theta}}$ dos estimadores de $\underline{\theta}$. Se define como *Eficiencia Relativa* de $\hat{\underline{\theta}}$ c/r a $\tilde{\underline{\theta}}$ a la cantidad

$$e(\hat{\underline{\theta}}, \tilde{\underline{\theta}}) = \frac{\mathbb{E} \left[\left(\hat{\underline{\theta}} - \underline{\theta} \right)^2 \right]}{\mathbb{E} \left[\left(\tilde{\underline{\theta}} - \underline{\theta} \right)^2 \right]}$$

obs: si $e(\hat{\underline{\theta}}, \tilde{\underline{\theta}}) < 1 \implies \hat{\underline{\theta}}$ es mas *eficiente* que $\tilde{\underline{\theta}}$.

Definición: Se llama *Cantidad de Información de Fisher* dada por \underline{x} sobre el parametro $\underline{\theta}$ a la cantidad

$$I_n(\underline{\theta}) = \mathbb{E} \left[\left(\frac{\partial \ln(L_{\underline{x}}(\underline{\theta}))}{\partial \underline{\theta}} \right)^2 \right]$$

Proposición:

$$I_n(\underline{\theta}) = \mathbb{V} \left(\frac{\partial \ln(L_{\underline{x}}(\underline{\theta}))}{\partial \underline{\theta}} \right) \vee I_n(\underline{\theta}) = -\mathbb{E} \left[\frac{\partial^2 \ln(L_{\underline{x}}(\underline{\theta}))}{\partial \underline{\theta}^2} \right]$$

Teorema: Si los valores muestrales son independientes y $I(\underline{\theta})$ es la cantidad de información de Fisher dada para cada x_i sobre el parametro $\underline{\theta}$, entonces

$$I_n(\underline{\theta}) = nI(\underline{\theta}) , \text{ Donde } I_n(\underline{\theta}) = \mathbb{E} \left[\left(\frac{\partial \ln(L_{\underline{x}}(\underline{\theta}))}{\partial \underline{\theta}} \right)^2 \right]$$

Teorema(Cota de Cramer-Rao): Si el dominio de χ de \underline{x} no depende del parametro $\underline{\theta}$, para todo estimador $\widehat{\underline{\theta}}$ de $\underline{\theta}$ se tiene que:

$$\mathbb{V} \left(\widehat{\underline{\theta}} \right) \geq \frac{\left(1 + b' \left(\widehat{\underline{\theta}} \right) \right)^2}{I_n \left(\underline{\theta} \right)}$$

Donde $b \left(\widehat{\underline{\theta}} \right) = \mathbb{E} \left(\widehat{\underline{\theta}} \right) - \underline{\theta}$ es el sesgo de $\widehat{\underline{\theta}}$

Obs: Si $\widehat{\underline{\theta}}$ alcanza la cota de Cramer-Rao, luego se dice que $\widehat{\underline{\theta}}$ es Eficiente.

References

- [1] H. Allende. *Probabilidades y estadística*. Universidad Técnica Federico Santa María, 1982.