Problemas Estadistica Descriptiva

Cristopher Morales Ubal
e-mail: c.m.ubal@gmail.com

Problemas

Problema 1 *Para cada una de las siguientes afirmaciones indique si ella es verdadera o falsa. Justifique.*

a) $\text{Me} = (Q_1 + Q_3)/2$*, siendo* Me = *Mediana,* $Q_i = i-$*ésimo cuartil* $(i = 1, 3)$*.*

b) Si el valor máximo entre $(x_1, x_2, \ldots, x_k) = 18$ *, entonces* Moda $= 18$*.*

c) Si una variable es de nivel de medición nominal , entonces la medida de tendencia central más adecuada es la mediana.

Problema 2 *Suponga que se tiene una muestra* $x_1, x_2, \ldots, x_n$ *y se ha calculado* $\overline{X}_n$ *y* s_n^2*, media y varianza, respectivamente. Después, se tiene disponible una observación adicional,* x_{n+1}*, la* $(n+1)-$*ésima observación. Sean* $\overline{X}_{n+1}$ *y* s_{n+1}^2 *la media y la varianza cuando se incluye la* $n+1$*-ésima observación en el calculo.*

a) Indique cómo puede calcularse $\overline{X}_{n+1}$*, utilizando* $\overline{X}_n$ *y* x_{n+1}

b) Demuestre que $(n+1)s_{n+1}^2 = ns_n^2 + \dfrac{n}{n+1} \cdot (x_{n+1} - \overline{X}_n)^2$

Problema 3 *Para la muestra aleatoria* $X_1 \leq X_2 \leq \ldots \leq X_n$ *se ha generado la siguiente medida de dispersión:*

$$T = \frac{1}{n} \sum_{i}^{n} |X_i - \text{Me}|$$

en donde Me *es la mediana del conjunto de datos. Demuestre que:*

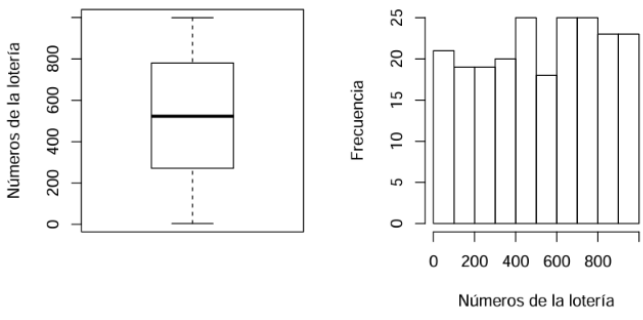
$$T = \overline{X}_n - \frac{2}{n} \sum_{X_i \leq \text{Me}} X_i + \frac{(1 + (-1)^{n+1})}{2n} \text{Me}$$

Ayuda: Suponga que existe r*, con* $1 \leq r < n$*, tal que* $X_1, X_2, \ldots, X_r \leq \text{Me}$*.*

Problema 4 *El siguiente conjunto de datos corresponde a* 218 *números (entre* 0 *y* 999*) como resultado de la lotería de Maryland. Los datos fueron recolectados en un periodo de* 32 *semanas entre Septiembre* 3*,* 1989 *a Abril* 14*,* 1990*. Los datos están disponibles en el proyecto de Conjuntos de Datos para Referencia, StRD perteneciente al Instituto Nacional de Estándares y Tecnología (NIST). Realice un análisis descriptivo de la variable de interés, basado en la siguiente información:*

n	min	Q_1	Q_2	Q_3	max
218	4.0	272.8	522.5	779.2	999.0

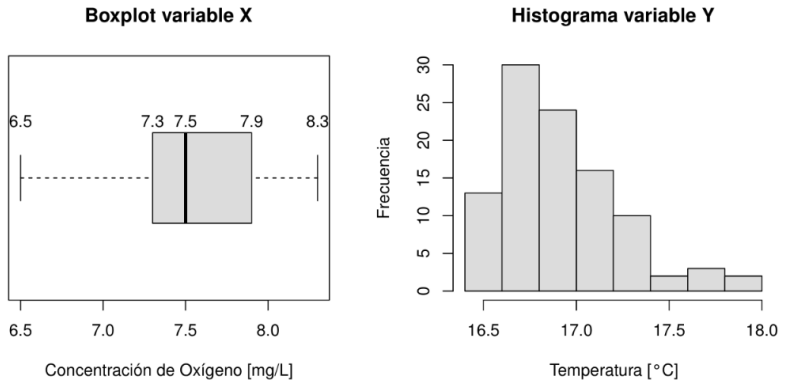
Se obtuvo además $\overline{x} = 518.96$*,* $s = 291.70$*,* $\sum_{i}^{n} z_i^3 = -20.07$ *y* $\sum_{i}^{n} z_i^4 = 390.38$*, donde* $z_i = (x_i - x)/s$*, para* $i = 1, \ldots, n$*, y los gráficos*



Problema 5 *Un grupo de científicos se encuentra realizando un estudio sobre las condiciones de vida marina en una localidad de Chile; para esto han tomado 100 muestras de agua de mar al azar en distintos puntos de la costa de Valparaíso, estas muestras se han almacenado en probetas a las cuales se les han medido las siguientes variables:*

X = Concentraciíon de oxígeno disuelto [mg/L].
Y = Temperatura al momento de la medición [°C].
Z = Presencia de materiales sólidos (medida como si o no).

La información obtenida de las variables X e Y se ha resumido en las siguientes gráficas:



a) Describa el tipo de muestreo que se llevó a cabo y caracterice los tipos de variables medidas junto con su escala de medición.

b) Para la variable X describa lo observado en el Boxplot*, luego reporte una medida de tendencia central y calcule una medida de dispersión.*

c) Describa el histograma de la variable Y, proponga medidas de tendencia central y de variabilidad adecuadas para ser calculadas.

Problema 6 *Las últimas cien ventas facturadas por un establecimiento se habían agrupado en cuatro intervalos de clase, recordamos tan sólo la siguiente información:*

i) El primer intervalo tiene seis semanas como extremo superior, una frecuencia relativa de 0.2 *y una amplitud de cuatro semanas.*

ii) La marca de clase del segundo y cuarto intervalo son ocho y cincuenta semanas, respectivamente.

iii) Hasta el segundo intervalo se acumulan 60 *ventas.*

iv) El tercer intervalo presenta una frecuencia de 30 *ventas y una amplitud de treinta semanas.*

Con la información anterior, construya la distribución de frecuencias y calcule la media, la mediana y la moda. Realice un gráfico que represente de mejor manera la distribución de los datos.

Problema 7 *La siguiente tabla corresponde a la distribución de las edades X de un grupo de personas:*

C_i	n_i
2 - 5	1
6 - 9	4
10 - 13	7
14 - 17	10
18 - 21	15
22 - 25	11
26 - 27	9

a) ¿Qué porcentaje de la muestra tiene más de 21 *años?*

b) Calcule $\overline{X}$, Me, Mo *y* s^2 *de la muestra.*

c) ¿Qué porcentaje de personas tiene menos de 20 años?

d) Calcule el coeficiente de variabilidad e indique el grado de simetría y achatamiento de la muestra. Justifique adecuadamente con los momentos centrales.

Problema 8 *Los siguientes datos corresponden a las cantidades máximas de emisión diarias de óxido de azufre (en toneladas) registradas según planta de emisión, en cierta zona industrial*

Cantidad de óxido(ton.)	Planta A	Planta B	Planta C
5-10	50	40	20
10-15	30	30	40
15-20	60	0	70
20-25	20	10	15
25-30	40	20	5

a) Indique la unidad de información y clasifique las variables según nivel de medición y tamaño de recorrido.

b) Entre las plantas B y C. ¿Cuál presenta mayor variabilidad relativa según la cantidad de óxido de azufre emitido?

c) ¿ Qué porcentaje de las emisiones producidas por la planta C supera las 28 *toneladas?*

Problema 9 *Una empresa con el fin de contratar un grupo de empleados operarios aplicó una prueba a todos los postulantes, a cada uno se les asignó el mismo trabajo. Los datos obtenidos son los siguientes:*

Table 1: Datos de tiempos de prueba aplicados a grupo de empleados operarios.

tiempo (hrs.)	postulantes
$1.45 - 2.15$	3
$2.15 - 2.85$	9
$2.85 - 3.55$	15
$3.55 - 4.25$	22
$4.25 - 4.95$	10
$9.95 - 5.65$	6
$5.65 - 6.35$	3

a) ¿Cuál es el tiempo de ejecución más común entre los postulantes?.

b) La empresa contratará a todos los postulantes que tengan un tiempo de ejecución superior o igual a 4.5*[hrs]. ¿Cuál es el porcentaje de postulantes contratados?.*

c) La empresa asignará a otras labores a los empleados que tengan un tiempo de ejecución mayor o igual a 3.3*[hrs]. ¿Cuál es el porcentaje de empleados (contratados) que se encuentran en esta situación?.*

d) Compare el resultado de la desigualdad de Tchevychev para $k = 1.55$ *con el mostrado por la tabla.*

e) ¿Son los tiempos de ejecución una medida que presenta una gran dispersión entre los empleados?. Utilice un indicador apropiado para la comparación.

Problema 10 *El señor de la gerencia de una importante empresa de ventas de maquinas industriales, sr. Camilo Rojas, resume las ventas realizadas por sus* 100 *vendedores pertenecientes a la región de Valparaíso en la siguiente tabla*

Table 2: Datos de ventas realizadas por 100 vendedores en la región de Valparaíso.

FRECUENCIAS					
Ventas en MM$	Marca de Clase	Absoluta	Relativa	Absoluta Acumulada	Relativa Acumulada
$[50.5, 100.5[$		15			
$[100.5, 150.5[$				35	
$[150.5, 200.5[$		20			
[, [	225.5			80	
$[250.5, 300.5[$					

a) Complete el recuadro.

b) Realice 2 gráficos adecuados a los datos.

c) ¿Sobre que valor de ventas se encuentra el 46% de los vendedores?

d) Si se consideran vendedores felices a aquellos que tengan ventas en el intervalo $(\overline{X} - 1.4S, \overline{X} + 1.4S)$*. ¿Qué porcentaje de los vendedores son considerados felices?.*

Problema 11 *Se realizo un estudio para determinar la relación entre la cantidad de goles anotados y la cantidad de goles recibidos por el equipo de futbol, "Colo-Colo", en los partidos jugados de visita. En base a una muestra aleatoria de 50 partidos jugados por dicho equipo se obtuvo la siguiente tabla de contingencia:*

Table 3: Tabla de contingencia de goles anotados (G_A) y goles recibidos (G_R)

$G_A \ddots G_R$	0	1	2	3	4
0	4	2	2	0	0
1	2	6	3	1	1
2	0	2	5	4	0
3	0	2	3	6	2
4	0	0	2	2	1

Donde $G_A =$ *goles anotados,* $G_R =$ *goles recibidos.*

a) Calcule el promedio de goles anotados y el promedio de goles recibidos en los partidos jugados de visita.

b) Determine el promedio y la desviación estándar de los goles anotados cuando se recibieron dos goles.

c) Determine el coeficiente de variación de la cantidad de goles anotados cuando se recibieron dos goles. ¿Es homogénea la muestra? Comente.

d) Determine el grado de asociación lineal entre los goles anotados y los goles recibidos. Interprete.

Problema 12 *En una investigación de contaminación, se midió el porcentaje medio de inversiones totales en Plantas y equipo destinado al control de ésta y la concentración de cloruro de hidrógeno máxima (HCl) en la atmósfera en 85 ciudades que se encontraban cercanas, la siguiente tabla resume los datos obtenidos:*

a) Reconozca, clasifique y determine las distribuciones marginales de ambas variables.

b) Determine los promedios para cada grupo de concentración de HCl.

c) determine el promedio y varianza para cada variable.

d) ¿Cuál es más homogénea?

Table 4: Datos de inversión y concentración de HCl en 85 ciudades

	% medio de inversiones [U.F]				
HCl	0-7	7-14	14-21	21-28	28-40
$0.5-0.8$	0	0	0	0	9
$0.8-1.1$	0	0	7	6	4
$1.1-1.4$	0	0	14	9	0
$1.4-1.7$	0	12	8	0	0
$1.7-2.0$	13	3	0	0	0

e) ¿Qué % de las ciudades tiene una concentración de HCL superior a 1.6*?*

f) ¿Es posible suponer que ambas variables presentan algún grado de relación? Justifique

g) Calcule los coeficientes del ajuste lineal e interprételos.

Problema 13 *Una importante cadena de pizzería con repartos a domicilio, desea revisar el tiempo empleado en la entrega de sus productos. Para ello ha decidido tomar una muestra de* 100 *repartidores a los cuales se les ha controlado el tiempo de demora, en minutos, para entregar los pedidos* (Y) *y la distancia, en kilómetros, entre la pizzería y el domicilio de destino* (X)*. Los resultados se presentan en la siguiente tabla:*

Table 5: Tabla de tiempos de demora (en min) de repartos a domicilio(Y) con respecto a la distancia (en km) entre la pizzeria y el domicilio (X).

$X \ddot{\cdot} Y$	10 - 15	15 - 20	25 - 35	35 - 45
2 - 6	5	10	3	1
6 - 10	13	6	5	7
10 - 14	7	0	3	11
14 - 18	0	2	12	15

a) Calcule e interprete las siguientes frecuencias n_{14}, n_{2+} *y* n_{+3}.

b) ¿Cuál es el promedio de distancia para los repartidores que se demoran a lo menos 25 *minutos en entregar el pedido?*

c) ¿Qué porcentaje de los repartidores se demora a lo menos 15 *minutos en entregar el pedido, si la distancia de destino está entre* 10 *y* 18 *kilómetros?*

d) El encargado de personal plantea que la ***variabilidad*** *en los tiempos de demora de los repartidores que recorren a lo menos de 10 kilómetros para llegar a destino es mayor al* 48, 5%*, por lo que se deberá realizar una nueva distribución en los turnos de los repartidores. ¿Está usted de acuerdo con el encargado? Justifique*

Problema 14 *En tiempos de elecciones se condujo una encuesta aleatoria entre ciudadanos con ingresos, para determinar si existe una relación entre su ingreso mensual en UF y la opinión respecto a la tenencia de armas. Se obtuvo la información presentada en la siguiente tabla:*

Ingreso $\ddot{\cdot}$ Opinión	A favor	En contra	Indeciso
30–50	110	64	26
20–30	90	116	14
10–20	55	35	10

a) Calcule el ingreso promedio de los encuestados.

b) Obtenga la media y la varianza de los votantes de las dos clases inferiores que se encuentran a favor de la tenencia de armas. Discuta la dispersión de los datos.

c) ¿Son independientes estas variables? Justifique.

Soluciones

Solución Problema 1

a) ***Falso**: La mediana solo seria el centro de los cuartiles si la variable fue perfectamente simétrica. Si la variable es asimétrica a la derecha (o a la izquierda), la mediana estará más cerca del Q_1 que del Q_3 (o viceversa en caso de asimetría hacia la izquierda).*

b) ***Falso**: La moda es el valor con mayor frecuencia en la muestra.*

c) ***Falso**: La variable en estudio es **Cualitativas**, luego el valor numérico de ella no tiene valor estadístico (no entrega información adicional). Luego, la más adecuada es la Moda.*